

Introduction

Pablo Mesejo

pmesejo@go.ugr.es

Universidad de Granada

Departamento de Ciencias de la Computación e Inteligencia Artificial



UNIVERSIDAD
DE GRANADA



DaSCI

Instituto Andaluz de Investigación en
Data Science and Computational Intelligence

Index

1. What is Computer Vision?
2. Related Disciplines and Some Definitions
3. Why is Computer Vision Difficult?
4. Computer Vision Applications
5. A Bit of History
6. Some of the Main Current Limitations

En esta presentación, comenzaremos definiendo qué es la visión por computador (computer vision en inglés), cuáles son las disciplinas y campos del conocimiento afines, por qué computer vision representa problemáticas difíciles, y cuáles son algunas de sus aplicaciones prácticas principales. Luego, haremos un breve y rápido recorrido histórico, desde los orígenes hasta la actualidad, y finalizaremos con algunas de las principales limitaciones actuales de los modelos de visión (extrapolables a otras herramientas, modelos y algoritmos de IA).

What is computer vision?

- AI branch that deals with problems related to **visual perception**:
 - Science/Engineering dealing with the **automatic interpretation of images and videos** (i.e. to extract “meaning” from pixels)
- Russell & Norvig’s AI book (Ch. 1) explicitly mentions 6 main AI branches:
 - Natural language processing
 - Knowledge representation
 - Automated reasoning
 - Machine learning
 - **Computer Vision (Ch. 27)**
 - Robotics



Necessary to pass the total Turing test,
which requires interaction with objects
and people in the real world

Stuart Russell and Peter Norvig. *Artificial Intelligence: A Modern Approach*. Global Edition. 4th edition. Pearson. 2021.
ISBN: 978-1-292-40113-3

3 of 92

La visión por computador es la rama de la inteligencia artificial que se ocupa de los problemas relacionados con la percepción visual. Podemos definirla como la ciencia y la ingeniería que estudian la interpretación automática de imágenes y vídeos; es decir, cómo extraer significado a partir de píxeles.

Se trata, además, de una de las ramas clásicas de la inteligencia artificial. De hecho, el conocido libro de Russell y Norvig la menciona explícitamente entre las principales áreas de la IA, junto con el procesamiento del lenguaje natural, la representación del conocimiento, el razonamiento automático, el aprendizaje automático y la robótica.

What is computer vision?

- “In computer vision, [we try] to **describe the world that we see** in one or more images and to **reconstruct its properties**, such as shape, illumination and color distributions.” Szeliski (2022)
- “Computer vision aims to duplicate the effect of human vision by electronically **perceiving and understanding an image**. [...] Giving computers the ability to see [...]” Sonka et al. (2015).
- “Computer vision aims at using **cameras** for analysing or **understanding scenes in the real world**.” Klette, R. *Concise computer vision*. Springer. 2014.

4 of 92

Existen multitud de definiciones de lo que entendemos por visión por computador, cada una de ellas poniendo el énfasis en aspectos diferentes. Por ejemplo, Richard Szeliski, en la segunda edición de 2022 del principal libro de referencia de la asignatura, señala que en visión por computador tratamos de describir el mundo que observamos en una o varias imágenes y reconstruir algunas de sus propiedades, como la forma, la iluminación o la distribución del color.

Otras definiciones ponen más énfasis en la capacidad de percibir y comprender imágenes, en el análisis mediante cámaras de escenas del mundo real o en la utilización de herramientas procedentes de la estadística, la geometría, la física y la teoría del aprendizaje para extraer descripciones del mundo a partir de imágenes o secuencias de imágenes. Finalmente, Russell y Norvig lo expresan de una forma especialmente intuitiva: se trata, en esencia, de recuperar información a partir del enorme flujo de datos que recibimos a través de ojos o cámaras.

What is computer vision?


- “Computer vision [...] uses **statistical methods** to disentangle data using models constructed with the aid of **geometry, physics, and learning theory**. [...] Computer vision’s great trick is extracting **descriptions of the world from pictures** or sequences of pictures”. Forsyth, D. A., & Ponce, J. (2012).
- “How to **recover information** from the flood of data that comes **from eyes or cameras**” Russell & Norvig. *Artificial Intelligence: A Modern Approach*. Pearson. 2021.

What is computer vision?

- Automatic understanding of images and videos
 - Computing properties of the 3D world from visual data (*measurement*)
 - Algorithms and representations to allow a machine to recognize objects, people, scenes, and activities (*perception and interpretation*)



Semantic information




Geometric information

6 of 92

En cualquier caso, podríamos decir que la visión por computador se ocupa fundamentalmente de extraer y analizar dos tipos de información a partir de imágenes y vídeos: información geométrica e información semántica.

En último término, el objetivo es llevar a cabo un proceso de comprensión automática del contenido visual. Desde este punto de vista, por un lado nos puede interesar recuperar propiedades del mundo tridimensional, es decir, realizar medidas sobre la escena (por ejemplo, estimar profundidad, forma, posición o estructura 3D), y ahí entraríamos en la parte más geométrica. Por otro lado, nos puede interesar reconocer objetos, personas, escenas o actividades, lo que nos sitúa en una dimensión más semántica, relacionada con la percepción y la interpretación del contenido de la imagen.



La visión por computador no es una disciplina aislada, como tampoco lo es ningún otro campo del conocimiento. No constituye un compartimento estanco, sino que mantiene numerosos puntos de contacto con otras áreas.

De entrada, forma parte de la inteligencia artificial, y se relaciona estrechamente con campos como el aprendizaje automático y profundo, la robótica o el procesamiento del lenguaje natural. Además, utiliza herramientas fundamentales procedentes de disciplinas como la estadística y la geometría.

Pero sus conexiones van mucho más allá. La visión por computador también puede abordarse desde la biología, estudiando por ejemplo los sistemas biológicos de percepción visual; desde la física, a través de la formación de la imagen, la luz y la óptica; desde la ciencia cognitiva y la neurociencia, incluyendo la psicología de la percepción; y, por supuesto, mantiene una relación muy estrecha con el procesamiento de imágenes y los gráficos por computador, que veremos con algo más de detalle en la siguiente diapositiva.

Related disciplines

- Computer Vision vs

- Computer Graphics (digital synthesis of visual content)



Image extracted from
https://upload.wikimedia.org/wikipedia/commons/5/5f/Utah_teapot_simple_2.png

- Image Processing (“low level” operations on images)



Image extracted from
<https://es.mathworks.com/help/images/ref/imgaussfilt.html>

Note: “machine vision” many times refers to the use of computer vision in industrial environments (for instance, automatic inspection, process control, etc.)

8 of 92

La idea esencial es que Computer Vision se ocupa principalmente del análisis, mientras que Computer Graphics se ocupa principalmente de la síntesis. En otras palabras, Computer Vision intenta inferir propiedades del mundo a partir de imágenes; Computer Graphics intenta generar imágenes a partir de una representación del mundo.

En Computer Vision partimos normalmente de una o varias imágenes y tratamos de extraer información de ellas: estimar la edad de una persona a partir de una fotografía, calcular la profundidad, reconstruir un objeto 3D a partir de imágenes 2D, localizar y clasificar objetos o generar una descripción de lo que está ocurriendo en una escena. En cierta medida, intentamos responder a preguntas como «¿qué hay en esta imagen y dónde está?». Es decir, buscamos analizar, interpretar y comprender imágenes o vídeos del mundo real.

En Computer Graphics, en cambio, la pregunta sería más bien «¿cómo puedo generar una imagen?». Partimos de modelos, geometría, materiales, luces o cámaras y tratamos de sintetizar una representación visual. Aquí aparecen conceptos como el diseño de curvas y superficies, las texturas, la rasterización («Tengo este triángulo del modelo 3D; ¿sobre qué píxeles de la imagen cae?») o el *ray tracing* («Tengo esta posición de la imagen que quiero generar; ¿qué punto de qué objeto 3D sería visible a través de ella?»). En términos muy simplificados, el objetivo puede ser transformar una escena 3D en una imagen 2D.


Ahora bien, esta separación no es absoluta. Son disciplinas con fronteras porosas, especialmente hoy. Técnicas como Neural Radiance Field o Gaussian Splatting (que infieren una representación de escena a partir de imágenes y luego sintetizan nuevas vistas), las GANs, o los modelos de difusión han hecho más difusa y permeable la frontera entre ambos campos y, en muchos casos, se sitúan en su intersección.

Por ejemplo, si partimos de un modelo CAD de un coche y queremos renderizarlo, estamos fundamentalmente en Computer Graphics. Si partimos de varias fotografías del coche y queremos recuperar su forma 3D, estamos en Computer Vision. Y si queremos generar un coche realista a partir de un *prompt* textual mediante un modelo de difusión, entramos en el ámbito de la generación de imágenes, un área que hoy se encuentra en una frontera difusa entre Computer Vision, Computer Graphics y la IA generativa.

Por otro lado, el procesamiento de imágenes (Image Processing) se ocupa, en términos generales, de realizar operaciones de bajo nivel sobre las imágenes, normalmente transformando directamente sus valores de píxel. Aquí entrarían, por ejemplo, operaciones de filtrado, reducción de ruido o realce, que veremos con más detalle en las próximas clases.

Otro término estrechamente relacionado es el de Machine Vision, que suele utilizarse para referirse a la aplicación de técnicas de visión por computador en entornos industriales. Por ejemplo, sistemas de inspección automática en fábricas, control de calidad, detección de defectos o control de procesos industriales.

Vision and graphics



Inverse problems: **analysis** and **synthesis**.

Slide credit: "Algorithms and applications in Computer Vision"
(Lihi Zelnik-Manor)

9 of 92

De manera general, Computer Vision y Computer Graphics pueden verse como problemas inversos: Computer Vision parte de imágenes e intenta recuperar información o propiedades de la escena que las generó (análisis), mientras que Computer Graphics parte de una representación de la escena y trata de sintetizar una imagen (síntesis).

Low-, mid- and high-level processing

- Different authors employ different definitions and taxonomies

- Forsyth, D. A., & Ponce, J. (2012)

Higher level image
representation
↓

- Early vision
 - Image filtering, texture analysis, stereopsis, structure from motion
- Mid-level vision
 - It involves coming up with image representations that are simultaneously compact and expressive (image segmentation, tracking)
- High-level vision
 - Image registration, image classification, object detection

- Sonka, M., Hlavac, V., & Boyle, R. (2015)

Higher level image
representation
↓

- *Low-level image processing* methods usually use very little knowledge about the content of images.
 - Digital image processing: Image compression, pre-processing methods for noise filtering, edge extraction, and image sharpening
- *High-level image understanding* tries to imitate human cognition. High-level data represent knowledge about the image content.

10 of 92

En esta diapositiva y en la siguiente vemos una caracterización clásica de las distintas tareas de visión por computador en función del nivel de representación, aunque conviene tener presente que existen matices y diferencias entre autores.

Por ejemplo, Forsyth y Ponce distinguen inicialmente lo que denominan *early vision*, donde entrarían tareas como el filtrado de imágenes o el análisis de texturas. A partir de ahí pasaríamos a un mayor nivel de abstracción, el *mid-level vision*, cuyo objetivo es obtener representaciones de la imagen que sean simultáneamente compactas y expresivas; aquí entraría, por ejemplo, la segmentación de imágenes. Finalmente tendríamos el *high-level vision*, donde estos autores incluyen tareas como el registro de imágenes, la clasificación de imágenes o la detección de objetos.

Si acudimos a Sonka, Hlavac y Boyle, encontramos una caracterización parecida. En el procesamiento de imágenes de bajo nivel, los métodos utilizan generalmente muy poco conocimiento acerca del contenido de la imagen; aquí entrarían tareas como la compresión, el filtrado de ruido, la extracción de bordes o el realce de imágenes. A continuación, pasaríamos a la comprensión de alto nivel, que pretende aproximarse a funciones cognitivas humanas y trabaja con representaciones que contienen conocimiento acerca del contenido de la imagen.

Low-, mid- and high-level processing

- Different authors employ different definitions and taxonomies
- Rafael C. González & Richard E. Woods (2008). Digital image processing. Pearson Prentice Hall. 3rd edition.
 - *Low-level processes* involve primitive operations (inputs and outputs are images)
 - image preprocessing to reduce noise, contrast enhancement, and image sharpening
 - *Mid-level processing* involves (inputs are images but outputs are attributes extracted from those images (e.g., edges, corners, or the identity of individual objects))
 - segmentation, objects description, and objects classification/recognition
 - *Higher-level processing* involves “making sense” of an ensemble of recognized objects and performing the cognitive functions normally associated with vision

Higher level image representation
↓

11 of 92

Una definición especialmente operativa, a mi juicio, es la de Gonzalez y Woods. Según estos autores, en los procesos de bajo nivel tanto la entrada como la salida son imágenes. En el nivel medio, la entrada sigue siendo una imagen, pero la salida pasa a ser algún tipo de atributo o representación extraída de ella, como bordes, esquinas, regiones u objetos. Finalmente, el procesamiento de alto nivel implica ya «dar sentido» al conjunto de objetos reconocidos y realizar funciones cognitivas normalmente asociadas con la visión humana.

Esta última clasificación tiene la ventaja de que permite entender intuitivamente cómo, a medida que subimos de nivel, nos alejamos progresivamente de los píxeles y nos acercamos a representaciones cada vez más abstractas y semánticas.

Every image tells a story



- Goal of computer vision: perceive the “story” behind the picture
- Compute properties of the world
 - 3D shape
 - Names of people or objects
 - What happened?

Slide credit: Noah Snavely
(https://www.cs.cornell.edu/courses/cs5670/2023sp/lectures/lec00_intro_for_web.pdf)

12 of 92

Cada imagen cuenta una historia y, en buena medida, los seres humanos somos animales que interpretamos y construimos historias. Cuando observamos una imagen somos capaces, muchas veces de manera casi inconsciente, de extraer una enorme cantidad de información y de formular hipótesis sobre lo que estamos viendo.

Por ejemplo, observemos la imagen de esta diapositiva. Aunque yo no supiera absolutamente nada de lo que ocurrió, podría empezar a realizar una serie de inferencias (que, por supuesto, podrían ser erróneas). Por su aspecto y por tratarse de una fotografía en blanco y negro, parece una imagen antigua. Además, al pie aparece escrito «La Gare Montparnasse, 1895». Estoy reconociendo automáticamente letras y números; interpreto *La Gare Montparnasse* como el nombre de un lugar en Francia y, utilizando mi conocimiento general, interpreto 1895 como una fecha. Como ambos aparecen asociados a la fotografía, infiero que probablemente indican el lugar y el momento en que ocurrió lo que estamos viendo.

En la imagen reconozco también un tren, pero está en una posición completamente anómala: parece haber descarrilado. A partir de la geometría de la escena puedo aventurar una explicación: quizá el tren no frenó a tiempo, atravesó el final de la estación y terminó cayendo hacia la calle. También identifico figuras humanas en la parte inferior derecha, algo borrosas (lo que podría deberse al tiempo de exposición de la fotografía), y una escalera que parece haber sido colocada para acceder a alguna zona de la escena.

Todo esto es interesante porque la mayor parte de esa información no está explícitamente escrita en la imagen. La estamos reconstruyendo combinando reconocimiento de objetos, geometría, texto, contexto, conocimiento previo y razonamiento.

Y esa es precisamente una buena manera de entender el objetivo último de la visión por computador: intentar recuperar la “historia” que hay detrás de una imagen, ya sea estimando propiedades geométricas del mundo (como su estructura o forma 3D), reconociendo personas y objetos, identificando qué está ocurriendo o incluso generando una descripción textual de la escena. Esa es exactamente la idea que resume la diapositiva: la dificultad que entraña obtener propiedades del mundo, reconocer qué aparece y comprender qué ha sucedido a partir de una imagen.

Can computers match (or beat) human perception?



- Yes and no (mainly no)
 - computers can be better at “easy” things
 - humans are better at “hard” things
 - **What is considered “hard” keeps changing**
- But huge progress
 - Accelerated in the last 10-15 years due to **deep learning**

Slide credit: Noah Snaveley
(https://www.cs.cornell.edu/courses/cs5670/2023sp/lectures/lec00_intro_for_web.pdf)

13 of 92

También podemos preguntarnos si las máquinas pueden igualar o incluso superar la percepción humana. La respuesta, al menos por el momento, sería sí y no; aunque me aventuraría a decir que, en términos muy generales, todavía principalmente no (aunque depende muchísimo de qué tarea concreta de percepción estemos comparando). Los ordenadores pueden superar claramente a los seres humanos en determinadas tareas relativamente «fáciles» (y pongo *fáciles* entre comillas), mientras que los humanos seguimos siendo mucho mejores en otras tareas visuales que podríamos considerar «difíciles». Pero hay que tener cuidado con estas etiquetas, porque lo que consideramos fácil o difícil cambia continuamente a medida que avanza la tecnología. Y, de hecho, el progreso de la visión por computador ha sido espectacular durante los últimos 10-15 años, con una aceleración enorme en la calidad de los resultados, impulsada fundamentalmente por el desarrollo del Deep Learning.

Can computers match (or beat) human perception?

– **What is considered “hard” keeps changing**

“People who have not worked in the field often underestimate the difficulty of the problem. This misperception that vision should be easy dates back to the early days of artificial intelligence, when it was initially believed that the cognitive (logic proving and planning) parts of intelligence were intrinsically more difficult than the perceptual components.” Szeliski (2022)

14 of 92

Para ilustrar mejor esta idea de que lo que consideramos difícil cambia continuamente, merece la pena detenerse en una reflexión de Richard Szeliski. El autor señala que las personas que no han trabajado en visión por computador tienden a infravalorar considerablemente la dificultad del problema.

Esta percepción aparece ya en los primeros años de la inteligencia artificial. En aquella época se tendía a pensar que las capacidades más claramente «cognitivas», como el razonamiento, la lógica, la resolución de problemas o la planificación, eran intrínsecamente más difíciles que las capacidades perceptivas.

Después de todo, razonar sobre un problema matemático nos exige concentración y esfuerzo, mientras que reconocer una cara, distinguir un coche de una bicicleta o interpretar una escena visual parece algo inmediato y natural.

Esta diferencia puede relacionarse, al menos de manera intuitiva, con la distinción entre los sistemas 1 y 2 popularizada por Daniel Kahneman. El sistema 1 engloba procesos rápidos, automáticos y que apenas requieren esfuerzo consciente, mientras que el sistema 2 interviene en tareas más lentas, deliberadas y que demandan atención, como realizar un cálculo complejo o seguir una cadena de razonamiento.


Buena parte de nuestra percepción visual funciona, desde nuestra experiencia subjetiva, como el sistema 1: abrimos los ojos y simplemente «vemos». No somos conscientes de la enorme cantidad de procesamiento necesaria para segmentar objetos, reconocerlos, estimar su posición y profundidad, interpretar movimientos, resolver ambigüedades o integrar toda esa información en una representación coherente de la escena.

Por el contrario, tareas asociadas al sistema 2 nos parecen difíciles precisamente porque somos conscientes del esfuerzo que requieren. Esto puede llevarnos a una intuición engañosa: asumir que aquello que nos cuesta más conscientemente también debe ser computacionalmente más difícil.

La historia de la inteligencia artificial y de la visión por computador mostró que no necesariamente es así. Tareas perceptivas que para un ser humano resultan prácticamente automáticas pueden requerir mecanismos extraordinariamente sofisticados y resultar enormemente difíciles de reproducir mediante una máquina.

Volveremos precisamente sobre esta cuestión más adelante, cuando hagamos un pequeño repaso histórico de la evolución de la visión por computador.

Human perception has its shortcomings



<https://twitter.com/pickover/status/1460275132958662657/>

Reality shatter. The physics, biology, and mathematics of human vision as it relates to geometrical patterns.

The lines on this checkerboard pattern are straight. (Optical illusion by Akiyoshi Kitaoka), Source: <https://bit.ly/3wNxuGQ>

Slide modified from Noah Snively
(https://www.cs.cornell.edu/courses/cs5670/2023sp/lectures/lec00_intro_for_web.pdf)


15 of 92

No obstante, también deberíamos ser cautos a la hora de ensalzar nuestras propias capacidades perceptivas, porque, como muestran esta diapositiva y la siguiente, la percepción humana también presenta importantes limitaciones.

Por ejemplo, en esta diapositiva vemos una ilusión óptica: aunque nuestro sistema perceptivo nos hace pensar que algunas de las líneas del patrón están inclinadas o deformadas, en realidad todas ellas son rectas. Es, por así decirlo, un engaño o fallo al que nos somete nuestro propio sistema visual.

Algo parecido ocurre en la diapositiva siguiente.

Human perception has its shortcomings




Copyright [A. Kitaoka](#) 2003

16 of 92

La imagen es completamente estática, no se trata de un GIF ni de una animación y, sin embargo, tenemos la sensación de que los círculos se mueven, especialmente cuando desplazamos la mirada o cambiamos nuestro punto de atención. De nuevo, el movimiento no está en la imagen: es una percepción generada por nuestro propio sistema visual.

Por tanto, aunque la percepción humana es extraordinariamente potente, tampoco debemos considerarla una referencia perfecta o infalible.

But humans can tell a lot about a scene from a little information...



Source: "80 million tiny images" by Torralba, et al.

Slide credit: Noah Snaveley
(https://www.cs.cornell.edu/courses/cs5670/2023sp/lectures/lec00_intro_for_web.pdf)

17 of 92

Pero lo que sí parece innegable es que los seres humanos somos capaces de extraer una enorme cantidad de información a partir de señales visuales muy pobres. Esta diapositiva es un buen ejemplo: la imagen está fuertemente pixelada y, sin embargo, seguimos siendo capaces de construir una interpretación bastante rica de la escena. Por ejemplo, podemos inferir que probablemente aparecen cuatro personas de pie. Entre las dos personas centrales parece haber algún elemento que podría ser una bandera. A partir de esas pocas pistas, y recurriendo a nuestro conocimiento previo y al contexto, podemos aventurar (siempre con la posibilidad de equivocarnos) que quizá estamos ante algún tipo de acto oficial o fotografía protocolaria: cuatro personas posando y mirando hacia la cámara, en el interior de una habitación y con una bandera situada detrás de ellas.

Lo interesante es que gran parte de esa interpretación no procede de detalles visuales claramente visibles, porque apenas los tenemos, sino de la capacidad de nuestro sistema perceptivo para combinar unas pocas evidencias con conocimiento previo y construir una hipótesis coherente sobre lo que está ocurriendo.

Why is computer vision difficult?

- We just take an example: Image Classification
 - Input: a single image
 - Output: Is there a cat in there? Yes/No?



→ CAT

Example taken from http://cs231n.stanford.edu/slides/2017/cs231n_2017_lecture2.pdf


18 of 92

Ahora veremos por qué la visión por computador es, en general, un campo difícil y, para transmitir esta idea de la manera más clara posible, vamos a partir de un ejemplo concreto.

Imaginaos un problema aparentemente muy sencillo: dada una imagen, queremos determinar si en ella aparece un gato o no. Es decir, estamos ante un problema de clasificación binaria.

Este ejemplo está tomado del curso Deep Learning for Computer Vision de Stanford, que constituye una de las principales referencias y recomendaciones de la asignatura.

The problem: semantic gap



This image is licensed under CC-BY 2.0

We perceive an image
(photons processed by our brain).
Holistic view of a cat.

```
[[105 112 108 111 104 99 106 99 96 103 112 119 104 97 93 87]
 [ 91 98 102 106 104 79 98 103 99 105 123 136 110 105 94 85]
 [ 76 85 90 105 128 105 87 96 95 99 115 112 106 103 99 85]
 [ 99 81 81 93 120 131 127 100 95 98 102 99 96 93 101 94]
 [106 91 61 64 69 91 88 85 101 107 109 98 75 84 96 95]
 [114 108 85 55 55 69 64 54 64 87 112 129 98 74 84 91]
 [133 137 147 103 65 81 80 65 52 54 74 84 102 93 85 82]
 [128 137 144 140 109 95 86 70 62 65 63 63 60 73 86 101]
 [125 133 148 137 119 121 117 94 65 79 80 65 54 64 72 98]
 [127 125 131 147 133 127 126 131 111 96 89 75 61 64 72 84]
 [115 114 109 123 150 148 131 118 113 109 100 92 74 65 72 78]
 [ 89 93 90 97 108 147 131 118 113 114 113 109 106 95 77 80]
 [ 63 77 86 81 77 79 102 123 117 115 117 125 125 130 115 87]
 [ 62 65 82 89 78 71 80 101 124 126 119 101 107 114 131 119]
 [ 63 65 75 88 89 71 62 81 120 138 135 105 81 98 110 118]
 [ 87 65 71 87 106 95 69 45 76 130 126 107 92 94 105 112]
 [118 97 82 86 117 123 116 66 41 51 95 93 89 95 102 107]
 [164 146 112 88 82 120 124 104 76 48 45 66 88 101 102 109]
 [157 170 157 120 93 86 114 132 112 97 69 55 70 82 99 94]
 [130 120 134 161 139 100 109 118 121 134 114 87 65 53 69 86]
 [128 112 96 117 150 144 120 115 104 107 102 93 87 81 72 79]
 [123 107 96 86 83 112 153 149 122 109 104 75 80 107 112 99]
 [122 121 102 80 82 86 94 117 145 148 153 102 58 78 92 107]
 [122 164 148 103 71 56 78 83 93 103 119 139 102 61 69 84]]
```

Our computer just “sees” a set of numbers (a matrix).
An image is just a big grid of numbers between [0, 255]:
e.g. 800 x 600 x 3 (3 channels RGB)

19 of 92


Los seres humanos percibimos una imagen (signifique exactamente eso lo que signifique desde el punto de vista perceptivo) y nuestro cerebro, a partir de la información que recibe a través de los ojos, construye una representación que nos permite reconocer, por ejemplo, un gato. Es decir, nosotros tenemos una percepción fundamentalmente holística: miramos la imagen y, de alguna manera, nuestro cerebro integra toda esa información y nos permite identificar directamente el objeto.

Sin embargo, aquí aparece un salto semántico importante. El ordenador no “ve” un gato. Lo que recibe es simplemente un conjunto de números organizado en forma de matriz. De algún modo, igual que nuestro cerebro procesa la información luminosa que llega a través de los ojos, el ordenador procesa valores numéricos asociados a la imagen. En una imagen digital convencional, esos valores suelen estar comprendidos, por ejemplo, entre 0 y 255.

Si hablamos de una imagen RGB, es decir, una imagen en color, podríamos tener, por ejemplo, una imagen de 800 filas por 600 columnas y 3 canales: uno correspondiente al rojo, otro al verde y otro al azul.

Por tanto, mientras que nosotros percibimos directamente “un gato”, el ordenador parte únicamente de una gran estructura numérica. El problema de la visión por computador consiste precisamente, en buena medida, en salvar esa distancia entre los valores numéricos de bajo nivel y los conceptos semánticos de alto nivel.

Challenges: Viewpoint variation



All pixels change when the camera moves!

1105	112	180	111	284	99	180	99	96	183	112	118	184	97	91	612	
1	91	98	182	184	79	18	183	99	181	112	118	114	185	94	611	
1	76	85	98	183	128	185	87	96	95	89	112	112	186	183	89	611
1	99	81	81	128	131	127	189	85	18	182	96	96	91	181	94	611
108	91	61	64	69	91	88	85	181	187	189	98	75	84	94	611	611
114	188	95	55	69	84	64	64	87	112	129	98	74	84	611	611	611
113	137	147	183	65	81	88	63	62	64	74	84	182	91	85	612	612
128	137	144	188	95	181	78	62	61	61	61	61	61	61	61	612	612
125	135	140	137	119	121	117	84	60	79	88	95	64	64	73	612	612
127	133	137	133	127	118	131	111	78	88	95	64	64	73	612	612	612
113	114	189	123	138	148	131	118	113	113	189	188	92	74	65	778	778
89	93	98	97	188	147	115	118	113	113	113	189	188	95	77	688	688
1	61	86	81	77	79	182	117	117	117	117	117	117	117	117	688	688
1	62	65	82	89	76	71	88	185	124	128	119	181	187	114	131	1118
1	62	65	75	89	89	71	82	128	128	128	128	128	128	128	128	1118
1	87	65	71	87	186	95	69	45	76	138	126	187	82	84	185	1118
118	97	82	88	117	123	118	66	41	51	59	59	59	59	59	59	189
104	146	112	88	82	128	124	184	78	48	45	66	88	181	182	189	189
1057	176	137	119	93	86	114	112	87	69	65	65	65	65	65	65	343
118	128	134	161	119	188	189	118	121	134	134	87	65	65	65	65	885
128	132	96	117	118	148	118	118	184	187	182	83	67	67	67	67	785
1223	187	96	96	83	112	112	149	122	189	184	75	88	187	112	991	991
1222	152	89	82	86	96	117	145	118	112	182	148	78	96	96	1891	1891
1222	144	149	183	71	56	78	83	83	183	119	139	182	61	69	8411	8411

Es decir, aunque para nosotros siga siendo evidentemente el mismo gato, la representación numérica que recibe el ordenador puede ser muy diferente. Los valores que antes aparecían en determinadas posiciones de la matriz pueden cambiar por completo simplemente porque la cámara se haya desplazado, haya rotado o esté observando al animal desde otro ángulo.

20

Challenges: Illumination



This image is CC0 1.0 public domain



This image is CC0 1.0 public domain



This image is CC0 1.0 public domain



This image is CC0 1.0 public domain

21 of 92

Pero los desafíos, como era de esperar, no terminan ahí. También podemos encontrarnos con cambios de iluminación: una misma escena puede verse muy distinta dependiendo de la intensidad, el color o la dirección de la luz y, sin embargo, el objeto sigue siendo el mismo.

Challenges: Deformation



This image by Umberto Salvagnin is licensed under CC-BY 2.0



This image by Umberto Salvagnin is licensed under CC-BY 2.0



This image by sare bear is licensed under CC-BY 2.0



This image by Tom.Tha is licensed under CC-BY 2.0

22 of 92

También aparecen deformaciones o cambios de pose. Un gato puede adoptar posturas muy diferentes, estirarse, encogerse, girarse o aparecer parcialmente doblado y, aun así, sigue siendo un gato.

Challenges: Intraclass variation



This image is CC0 1.0 public domain



slide credit: Fei-Fei, Fergus & Torralba

23 of 92

Otro problema importante es la variación intraclass. Dentro de una misma categoría no existe un único modelo visual. No todos los gatos tienen la misma forma, color o tamaño. Lo mismo ocurre con categorías como las sillas o los sofás: existen diseños extremadamente distintos entre sí y, aun así, los seres humanos somos capaces de reconocer que todos pertenecen a la misma clase funcional o semántica.

Challenges: Background Clutter



This image is CC0 1.0 public domain



This image is CC0 1.0 public domain

24 of 92

También puede variar considerablemente el fondo. En una imagen el gato puede aparecer sobre un fondo anaranjado u ocre y, en otra, sobre nieve blanca. Para nosotros sigue siendo sencillo reconocerlo, aunque cambie por completo el contexto visual que lo rodea.

Challenges: Occlusion



This image is CC0.1.0 public domain



This image is CC0.1.0 public domain



This image by jorsson is licensed under CC-BY 2.0

How on earth can a human know that there's a cat in there?



25 of 92

Y, además, podemos enfrentarnos a oclusiones: parte del objeto puede estar tapada por otro elemento de la escena. Aun viendo solo una fracción del gato, muchas veces seguimos siendo capaces de inferir correctamente que se trata de un gato.

De hecho, el ejemplo de la derecha de esta diapositiva es especialmente interesante. ¿Cómo sabemos que lo que aparece ahí es realmente un gato y no, por ejemplo, un mapache o una gineta? Si buscamos imágenes de un mapache, veremos que determinadas características, como la cola, pueden resultar visualmente bastante parecidas.

Lo interesante es que nosotros no tomamos la decisión únicamente a partir de la apariencia local del animal, sino que utilizamos también información contextual. Por un lado, toda la secuencia de ejemplos que estamos viendo en esta presentación está construida alrededor de la categoría “gato”, así que resulta razonable pensar que esta imagen forma parte de la misma serie. Pero, además, observamos un entorno doméstico, y ahí entra en juego nuestro conocimiento del mundo: es mucho más habitual encontrar un gato dentro de una casa que un mapache o una gineta.

A esto se suma también nuestro conocimiento sobre el comportamiento esperado de los animales. La postura, la interacción con el entorno y la propia escena encajan con lo que esperamos encontrar en un gato doméstico.

Por tanto, reconocer objetos no consiste únicamente en analizar sus píxeles de manera aislada. También intervienen el contexto de la escena, el conocimiento previo y el sentido común, que nos ayudan a desambiguar situaciones visuales que, consideradas únicamente a partir de la apariencia, podrían resultar mucho menos evidentes.

Challenges: Occlusion

ChatGPT 5.2 ▾



Describeme lo que ves en la siguiente imagen.

Veo un sofá de cuero color beige con varios cojines acolchados. En el asiento central, uno de los cojines está ligeramente levantado o desplazado, y por una abertura entre los cojines asoma una cola peluda con anillos oscuros y claros, que parece ser la cola de un mapache. A la derecha también se alcanza a ver un pequeño mechón de pelo blanco sobresaliendo. Da la impresión de que el animal está escondido dentro del sofá.



26 of 92

De hecho, en relación con la diapositiva anterior, la imagen de la derecha se la proporcioné a ChatGPT 5.2 en febrero de 2026 y le pedí simplemente que me la describiese. La respuesta que obtuve es la que podéis observar en esta diapositiva. Sin duda, se trata de una descripción muy buena y, desde luego, muchísimo mejor que las que proporcionaban los sistemas clásicos de *image captioning* hace diez años. Sin embargo, resulta curioso que el modelo identifique lo que aparece en la imagen como la cola de un mapache.

Al menos en nuestro contexto sociocultural, esa no sería probablemente la interpretación más habitual: no es especialmente frecuente encontrarse un mapache dentro de una vivienda en España. Por eso, el ejemplo resulta llamativo. No podemos afirmar a partir de un único caso cuál es la causa del error, pero no es descartable que refleje algún tipo de sesgo aprendido a partir de los datos de entrenamiento. Por ejemplo, el modelo podría haber estado expuesto a una distribución de imágenes en la que los mapaches aparecen con mucha mayor frecuencia de la que cabría esperar en nuestro entorno.

Este ejemplo nos recuerda, por tanto, que incluso sistemas actuales con capacidades visuales muy avanzadas pueden realizar interpretaciones plausibles pero potencialmente incorrectas, y que esas interpretaciones estarán condicionadas por la distribución de los datos con los que han sido entrenados.

Challenges: occlusion, clutter



27 of 92

Luego, por supuesto, existen muchas otras situaciones ambiguas y problemáticas, por ejemplo debido al solapamiento entre distintos objetos o a la presencia de oclusiones, que pueden dificultar el reconocimiento.

Challenges: Motion



How do we know that this isn't a headless bird? Why do we infer that there is movement?



Source: S. Lazebnik

28 of 92

Otro desafío importante es la presencia de movimiento. Por ejemplo, en esta diapositiva, ¿cómo somos capaces de interpretar correctamente lo que está haciendo este animal?

A primera vista podríamos preguntarnos incluso si estamos viendo un pájaro sin cabeza, pero evidentemente esa explicación es muy poco plausible. Lo que observamos encaja mucho mejor con un comportamiento normal de un ave, aparentemente refrescándose en una fuente.

Aquí vuelve a intervenir nuestro conocimiento previo del mundo. Vemos gotas de agua suspendidas en el aire, pero sabemos que están en movimiento y que, debido a la gravedad, acabarán cayendo. Del mismo modo, asumimos que el pájaro sí tiene cabeza; lo que ocurre es que la está moviendo con suficiente rapidez como para que la cámara no pueda capturarla de forma nítida en ese instante.

De nuevo, este tipo de situaciones muestra que interpretar una imagen no consiste únicamente en analizar una configuración estática de píxeles. Muchas veces necesitamos inferir movimiento, dinámica y causas físicas a partir de una única observación visual, y en esos escenarios la existencia de un modelo mental del mundo físico resulta fundamental.

Challenges: Inherent ambiguity and scale

- Many different 3D scenes could have given rise to a particular 2D picture



- We often must use **prior knowledge** about the **world's structure**

29 of 92

También, por supuesto, nos encontramos con imágenes inherentemente ambiguas debido a la escala y a la proyección. Una misma imagen 2D puede ser compatible con múltiples escenas 3D diferentes.

De nuevo, los seres humanos resolvemos gran parte de esta ambigüedad utilizando nuestro conocimiento a priori sobre la estructura y las dimensiones habituales del mundo. En esta diapositiva, por ejemplo, sería posible interpretar literalmente que estamos viendo una calabaza del tamaño de una casa, una mariposa gigantesca ocupando buena parte de una acera o una niña de 4 metros de altura jugando al baloncesto. Pero todas esas interpretaciones son extremadamente improbables (por no decir imposibles, en el mundo en que vivimos).

Lo que hacemos es utilizar nuestro conocimiento sobre los tamaños habituales de los objetos y sobre las relaciones de profundidad para inferir una explicación mucho más razonable de la escena.

Este tipo de ejemplos ilustra una idea fundamental: la imagen 2D no determina de manera única la escena 3D que la ha generado, y la percepción necesita recurrir a conocimiento previo y restricciones sobre cómo suele ser el mundo.

There are lots of visual cues we can use...

Depth cues: Linear perspective



Depth cues: Aerial perspective



Depth ordering cues



Shape cues: Texture gradient



Shape and lighting cues: Shading



Position and lighting cues: Cast shadows




30 of 92

Por tanto, como hemos visto hasta ahora, a la hora de interpretar imágenes utilizamos todo tipo de claves visuales que nos ayudan a reconstruir la estructura de la escena. Por ejemplo, en la imagen de arriba a la izquierda aparece la perspectiva lineal. Evidentemente, los objetos que vemos al fondo no son realmente muchísimo más pequeños que los que aparecen en primer plano; lo que ocurre es que, debido a la perspectiva, su tamaño proyectado sobre la imagen disminuye a medida que aumenta la distancia respecto a la cámara.

En la imagen de abajo a la derecha ocurre algo diferente. Aquí es la (supuesta) sombra la que modifica por completo nuestra interpretación de la escena. Al cambiar artificialmente su posición respecto a la persona, nuestro sistema visual infiere una relación espacial distinta y nos hace percibir que la persona está flotando en el aire. Es decir, no interpretamos una imagen únicamente a partir de la forma y el color de los objetos, sino también utilizando perspectiva, sombras, oclusiones, tamaños relativos y otras claves visuales que nos permiten inferir profundidad y estructura tridimensional.

There are lots of visual cues we can use...

Grouping cues: Similarity (color, texture, proximity)



Grouping cues: "Common fate"



31 of 92

Y existen también otras claves que utilizamos para organizar e interpretar la información visual. Por ejemplo, empleamos claves de agrupamiento basadas en la similitud de color o textura, en la proximidad entre elementos o en la continuidad de determinadas estructuras.

En la figura de la derecha aparece otro ejemplo interesante. Si observamos la imagen con algo de calma, podemos reconocer tres filas de camellos avanzando por el desierto, vistos desde una perspectiva cenital. Las zonas más oscuras que aparecen junto a ellos no corresponden a otros objetos, sino a las sombras proyectadas por los propios animales.

Además, percibimos que los camellos de cada fila forman parte de una misma estructura porque comparten una dirección de movimiento común. Esa coherencia en el desplazamiento actúa también como una clave de agrupamiento: elementos que avanzan de manera coordinada tienden a percibirse como pertenecientes a una misma unidad o grupo.

De nuevo, la percepción no depende únicamente de características locales, sino también de cómo distintos elementos se relacionan entre sí dentro de la escena.

The state of Computer Vision and AI: we are really, really far away.

Oct 22, 2012

<https://karpathy.github.io/2012/10/22/state-of-computer-vision/>



- ❖ Bunch of people in a hallway.
- ❖ There are 3 mirrors in the scene so some of those people are “fake” replicas from different viewpoints.
- ❖ You recognize Obama [...] he is in his suit [...] he is surrounded by other people with suits.
- ❖ There’s a person standing on a scale.
- ❖ Obama has his foot positioned just slightly on top of the scale.
- ❖ Obama is leaning in on the scale, which applies a force on it. Scale measures force that is applied on it => it will over-estimate the weight of the person standing on it.
- ❖ The person measuring his weight is not aware of Obama doing this.
- ❖ People are self-conscious about their weight.
- ❖ There are people in the back who find the person’s imminent confusion funny.
- ❖ The perpetrator is the president, making it even a little more funnier.

Y esta diapositiva me parece especialmente interesante. Corresponde a una entrada del blog de Andrej Karpathy, un investigador que os recomiendo encarecidamente. Karpathy realizó su doctorado en la Universidad de Stanford bajo la supervisión de Fei-Fei Li, fue uno de los miembros fundadores de OpenAI y posteriormente trabajó en Tesla, donde llegó a dirigir el equipo de computer vision de Autopilot. A mí me parece, además de un gran investigador, un excelente docente y divulgador. La entrada es de octubre de 2012. Han pasado ya catorce años y, durante este tiempo, la visión por computador ha avanzado extraordinariamente. Sin embargo, conservo este ejemplo precisamente porque permite apreciar la profundidad de algunos de los problemas a los que se enfrenta el campo. Muchas tareas que resultaban extremadamente difíciles en 2012 han mejorado muchísimo, pero comprender completamente una escena como esta sigue requiriendo integrar una enorme cantidad de información.

¿Qué vemos aquí? En primer lugar, observamos a varias personas en el interior de un edificio, aparentemente en una especie de pasillo. Pero inmediatamente detectamos algo más: hay varios espejos. Por tanto, no todas las figuras humanas que aparecen en la imagen corresponden a personas distintas; algunas son simplemente reflejos.

Además, reconocemos en el centro a Barack Obama. No estamos identificando únicamente la categoría «persona», sino a un individuo concreto y, con ello, activamos todo nuestro conocimiento previo sobre quién es.

A la izquierda vemos a una persona subida a una báscula. Obama está colocando el pie sobre ella y ejerciendo presión hacia abajo, de manera que la báscula marcará un peso superior al real. La persona que está pesándose aparentemente no es consciente de lo que está ocurriendo, mientras que otras personas presentes sí parecen entender la situación.

Entendemos que se trata de una broma porque inferimos intenciones, estados mentales y expectativas: sabemos qué espera ver la persona que se está pesando, sabemos que Obama está alterando deliberadamente el resultado y anticipamos la confusión que probablemente experimentará cuando observe la cifra. Además, nuestro conocimiento social nos dice que el peso corporal puede tener relevancia para las personas por razones de salud, autoestima o apariencia, y el hecho de que quien realiza la broma sea precisamente el presidente de Estados Unidos añade todavía más elementos a la situación.

Por tanto, para comprender plenamente esta imagen no basta con detectar objetos o personas. Hay que combinar reconocimiento visual, geometría de la escena, conocimiento del mundo, identidad de las personas, relaciones causales, intencionalidad humana, estados mentales, normas sociales y sentido del humor. Entrelazar correctamente todos esos niveles de significado es una tarea extraordinariamente compleja para una máquina.

Si proporcionáis esta figura a un modelo multimodal como ChatGPT o Gemini y le pedís que describa lo que está ocurriendo, veréis que la respuesta puede ser extraordinariamente precisa. Es capaz de identificar la báscula, la acción que realiza la persona que pisa sobre ella, la broma y, en muchos casos, incluso buena parte del contexto de la escena.

Pero este ejemplo también introduce una reflexión importante y una cierta “trampa”. Se trata de una fotografía muy conocida, tomada en 2010 durante una visita a la Universidad de Texas en Austin y ampliamente difundida por medios de comunicación y fuentes oficiales. Por tanto, es perfectamente posible que esta imagen, y descripciones textuales de ella, hayan formado parte de los datos de entrenamiento de buena parte de estos modelos.

Esto nos obliga a plantearnos una pregunta metodológicamente importante: ¿hasta qué punto el modelo está interpretando realmente la escena a partir de la información visual y hasta qué punto está recuperando o reconstruyendo conocimiento aprendido previamente durante el entrenamiento sobre una imagen concreta?

Distinguir entre comprensión visual genuina y “memorización” parcial de ejemplos conocidos no es trivial, y constituye uno de los desafíos fundamentales a la hora de evaluar las capacidades reales de los modelos multimodales.

Computer Vision Applications

Keep in mind that all these applications can serve as references, guidance, and inspiration when proposing topics for your final course project.

A continuación vamos a ver distintas aplicaciones de la visión por computador. El objetivo no es profundizar ahora en ninguna de ellas, sino presentarlas de manera superficial para que tengáis una visión de conjunto de algunas de las tareas, problemáticas y ámbitos en los que la visión por computador puede resultar de utilidad.


El mensaje que quiero transmitir es doble. Por un lado, quiero que veáis que la visión por computador tiene actualmente un despliegue tecnológico amplísimo y que sus aplicaciones son extraordinariamente variadas. Por otro, me gustaría que esta sección os resultase útil de cara al proyecto final de la asignatura.

En principio, salvo que no tengáis ninguna idea sobre qué os gustaría hacer y me pidáis consejo o propuestas concretas, el proyecto final debe surgir de vuestra propia iniciativa. Precisamente por eso, espero que este recorrido por distintas aplicaciones os sirva como referencia y os permita extraer ideas, identificar qué tareas o ámbitos os resultan más atractivos y empezar a intuir por dónde podría orientarse vuestro proyecto.

Además, el proyecto final no tiene por qué consistir en desarrollar una de estas aplicaciones en su totalidad. Puede centrarse, por ejemplo, en un análisis teórico o empírico de alguna cuestión relacionada con ellas, en la implementación de una parte concreta de una aplicación, en un estudio comparativo entre distintas metodologías o en cualquier otro planteamiento suficientemente fundamentado y relacionado con la visión por computador.

En definitiva, esta sección no está aquí simplemente para completar el temario. Tiene dos objetivos claros: que adquiráis una idea, aunque necesariamente parcial, de la amplitud del campo y de su enorme utilidad práctica, y que os sirva como fuente de inspiración y referencia para empezar a pensar en vuestro proyecto final de la asignatura.

Automatic 3D reconstruction from Internet photo collections



Noah Snavely et al. "Scene reconstruction and visualization from community photo collections."
Proceedings of the IEEE 98.8 (2010): 1370-1390.

34 of 92

Desde hace años existen aplicaciones capaces de realizar la reconstrucción automática en 3D de objetos o monumentos a partir de grandes colecciones de fotografías, incluso utilizando imágenes disponibles públicamente en Internet.

Por ejemplo, podemos reconstruir tridimensionalmente monumentos como la Estatua de la Libertad o el Coliseo de Roma a partir de fotografías tomadas desde múltiples puntos de vista por personas diferentes, con cámaras distintas, condiciones de iluminación variables y sin que esas imágenes hayan sido capturadas expresamente para realizar la reconstrucción.

El sistema debe identificar correspondencias entre las distintas imágenes, estimar desde qué posición y orientación fue tomada cada fotografía y, a partir de toda esa información, inferir la estructura tridimensional de la escena.

City-scale 3D reconstruction (Large-scale Structure-from-Motion)

Reconstruction of Dubrovnik, Croatia, from ~40,000 images (Source: Noah Snavely)

<https://www.youtube.com/watch?v=mUhYJnd1TqE>


35 of 92

También es posible realizar reconstrucciones 3D a gran escala mediante técnicas de Structure from Motion (SfM). Por ejemplo, en esta diapositiva podéis ver una reconstrucción tridimensional de la ciudad de Dubrovnik, en Croacia, obtenida a partir de aproximadamente 40.000 imágenes.

Este tipo de sistemas aprovecha fotografías tomadas desde numerosos puntos de vista para estimar simultáneamente la posición de las cámaras y la geometría tridimensional de la escena.

Tanto esta aplicación como la anterior están estrechamente relacionadas con la rama geométrica de la visión por computador, en la que conceptos como la geometría proyectiva, la calibración de cámaras, las correspondencias entre imágenes y la reconstrucción 3D desempeñan un papel fundamental.

Depth estimation from a single image (Monocular Depth Estimation)



Zhengqi Li and Noah Snavely. "MegaDepth: Learning single-view depth prediction from internet photos." *Proceedings of the IEEE conference on computer vision and pattern recognition*. 2018.

36 of 92

También podemos intentar estimar la profundidad de la escena a partir de una única imagen. Esta tarea se conoce como monocular depth estimation.

El objetivo es asignar a cada píxel una estimación de su distancia respecto a la cámara, aun disponiendo solamente de una vista. Esto es especialmente interesante porque, a diferencia de la visión estereoscópica, aquí no contamos con dos cámaras ni con múltiples puntos de vista: el sistema debe inferir la profundidad relativa a partir de las claves visuales presentes en una sola imagen.

Improve photos (“Computational Photography”)



Super-resolution

(W. Yang et al. "Deep learning for single image super-resolution: A brief review." *IEEE Transactions on Multimedia* 21.12 (2019): 3106-3121)



Depth of field on cell phone camera (Picture without (left) and with (right) portrait mode; good way to draw the viewer's attention to a subject)
[Pixel 2](#), [Pixel 3](#) and [Pixel 4](#).



Removing objects

(<https://blog.google/products/photos/magic-eraser/>)

Slide adapted from
Noah Snavey

37 of 92

Low-light photography
(S. W. Hasinoff et al. "Burst photography for high dynamic range and low-light imaging on mobile cameras." *ACM Transactions on Graphics (ToG)* 35.6 (2016): 1-12)



Luego también podemos encontrar aplicaciones relacionadas con la fotografía computacional, que en ocasiones se considera incluso un campo en sí mismo. Dicho de una manera muy sencilla, su objetivo es utilizar técnicas computacionales para mejorar fotos.

Aquí entrarían, por ejemplo, las técnicas de superresolución, en las que partimos de una imagen de baja resolución e intentamos obtener otra de resolución mucho mayor.

También encontramos aplicaciones como el modo retrato de los teléfonos móviles, donde el sistema identifica al sujeto principal, separa aproximadamente primer plano y fondo y difumina este último para centrar la atención en la persona fotografiada.

Otra posibilidad es la edición inteligente de imágenes, por ejemplo eliminando objetos que no nos interesan o reconstruyendo automáticamente las regiones que quedan ocultas tras eliminarlos.

Y también tenemos la fotografía en condiciones de baja luminosidad (*low-light photography*), donde el objetivo es mejorar imágenes capturadas con muy poca luz, reduciendo ruido y recuperando, en la medida de lo posible, detalle, contraste y color.

Self-driving cars



Source: <https://analyticsindiamag.com/what-is-the-difference-between-computer-vision-and-image-processing/>

Tesla AI Day: <https://www.youtube.com/watch?v=j0z4FweCy4M&t=2814s>

38 of 92

Y, del mismo modo, la visión por computador se utiliza en una enorme variedad de tareas y aplicaciones.

Por ejemplo, aparece en conducción autónoma, donde es necesario detectar vehículos, peatones, señales, carriles y otros elementos relevantes de la escena.

Image generation



"Progressive Growing of GANs for Improved Quality, Stability, and Variation" (Karras et al., 2017)

39 of 92

También encontramos aplicaciones generativas, como la generación de imágenes faciales sintéticas,...

Which face is real?

Click on the person who is real.



<https://www.whichfaceisreal.com/>

40 of 92

Which face is real?

Click on the person who is real.



<https://www.whichfaceisreal.com/>

41 of 92

Which face is real?

Click on the person who is real.



<https://www.whichfaceisreal.com/>

42 of 92

Independientemente de que acertemos, o no, cuál es la imagen real y cuál es la imagen generada, ya el mero hecho de plantearnos la pregunta es un buen indicador del nivel que ha alcanzado la tecnología. No obstante, por el momento, todavía hay elementos que nos permiten identificar imágenes generadas con IA: en muchas ocasiones tienen una claridad y “limpieza” un poco antinatural, y/o aparecen ciertos problemas con algunos detalles finos (como los dientes o el pelo), y/o hay elementos que aparecen ligeramente fusionados o con una configuración extraña (como puede ser el pelo y la textura de la ropa o el fondo). En cualquier caso, como comentaba, el grado de realismo y veracidad es tal, que ya el mero hecho de que dudemos y nos planteemos la pregunta da una buena medida del avance tecnológico en el campo.

Image generation (from text prompts)

color photograph of marie curie with a marvel ironman suit



color photograph of batman and queen elizabeth the second of united kingdom



color photograph of a dog in a coral reef



<https://stability.ai/blog/stable-diffusion-public-release>

43 of 92

la generación de imágenes a partir de descripciones textuales...

Video generation/animation (from text prompts)



<https://www.youtube.com/watch?v=BTeC4n1veF4>

<https://kling.kuaishou.com/en>

44 of 92

o la generación y edición de vídeo condicionada por texto.


Video generation/animation (from text prompts)



Sora: <https://openai.com/index/video-generation-models-as-world-simulators/>

45 of 92

Style Transfer



“A Neural Algorithm of Artistic Style”
(Gatys et al., 2015)

46 of 92

Otra tarea clásica es la transferencia de estilo, en la que partimos de una imagen de contenido y de una referencia de estilo, y tratamos de generar una nueva imagen que mantenga el contenido de la primera pero adopte las características visuales de la segunda.

Image colorization



"Colorful Image Colorization" (Zhang et al., 2016)

47 of 92

También podemos realizar colorización de imágenes en blanco y negro,...

Image reconstruction/inpainting



“Image Inpainting for Irregular Holes Using Partial Convolutions” (Liu et al., 2018)



48 of 92

así como image inpainting, donde el objetivo es reconstruir regiones ausentes o dañadas de una imagen de manera visualmente plausible, a partir del contexto disponible y de lo aprendido por el modelo.

Face detection

Face recognition

Face analysis



Many companies develop or use face detection, recognition, and analysis technologies.

See, for instance,

<https://hertasecurity.com/es/>


49 of 92

Dentro del análisis de personas encontramos tareas como la detección facial, que consiste en localizar caras en una imagen; el reconocimiento facial, donde además se intenta asignar una identidad; y distintas formas de análisis facial, como la estimación de edad, expresión, atributos o pose de la cabeza.


Detection, semantic segmentation, instance segmentation




image classification



object detection



semantic segmentation



instance segmentation

Lin, Tsung-Yi, et al. "Microsoft COCO: Common objects in context." *Computer Vision—ECCV 2014: 13th European Conference, Zurich, Switzerland, September 6–12, 2014, Proceedings, Part V 13*. Springer International Publishing, 2014.

50 of 92

También entre las tareas clásicas de visión por computador encontramos la clasificación de imágenes. En este caso, dada una imagen de entrada, el objetivo es asignarle una o varias categorías en función de los elementos que aparecen en ella. Por ejemplo, podríamos identificar la presencia de una persona, ovejas y un perro. Cuando una misma imagen puede recibir varias etiquetas simultáneamente, hablamos más específicamente de clasificación multietiqueta.

La detección de objetos supone un paso adicional: no solo queremos saber qué clases de objetos aparecen en la imagen, sino también localizar aproximadamente dónde se encuentra cada uno de ellos. Para ello se utilizan normalmente bounding boxes, es decir, cajas delimitadoras que encierran cada objeto detectado. En este ejemplo vemos, por ejemplo, una caja roja alrededor del perro, cajas azules alrededor de las ovejas y una caja cian alrededor de la persona.

Es decir, la clasificación de imágenes intenta responder a la pregunta: ¿qué aparece en la imagen?


La detección de objetos añade información espacial y trata de responder a: ¿qué aparece y dónde está?

Después tendríamos la segmentación semántica, donde el objetivo es asignar una clase a cada píxel de la imagen. En este sentido, puede verse como un problema de clasificación a nivel de píxel: cada píxel se etiqueta, por ejemplo, como persona, oveja, perro, fondo, etc. Pero la segmentación semántica no diferencia instancias de la misma clase.

Aquí es donde entraría la segmentación de instancias, donde no basta con clasificar cada píxel, sino que además se pretende distinguir las distintas instancias individuales de una misma clase.

Por eso, en el ejemplo, todas las ovejas tendrían la misma etiqueta semántica ("oveja"), pero en segmentación de instancias aparecen diferenciadas como oveja 1, oveja 2, oveja 3, oveja 4 y oveja 5, normalmente representadas con colores distintos.

Image classification and tagging




Adapted from
Fei-Fei Li

51 of 92

Por supuesto, también hay aplicaciones que, dada una imagen de entrada, permiten etiquetar características de las mismas....

Object detection

- find pedestrians




Adapted from
Fei-Fei Li

52 of 92

Detectar peatones....

Activity recognition




Adapted from
Fei-Fei Li

53 of 92

Reconocer actividad humana...

Image description/captioning



This is a busy street in an Asian city. Mountains and a large palace or fortress loom in the background. In the foreground, we see colorful souvenir stalls and people walking around and shopping. One person in the lower left is pushing an empty cart, and a couple of people in the middle are sitting, possibly posing for a photograph.

Adapted from
Fei-Fei Li

54 of 92

Permiten describir imágenes, es decir, realizar lo que habitualmente se conoce como *image captioning*: dada una imagen de entrada, generar automáticamente un texto que describa su contenido.

Human pose estimation in videos

Real-time Multi-Person 2D Pose Estimation Using Part Affinity Fields


Zhe Cao, Tomas Simon, Shih-En Wei, Yaser Sheikh
Carnegie Mellon University

<https://www.youtube.com/watch?v=pW6nZXeWIGM>

55 of 92

También hay sistemas de estimación de la pose corporal en vídeo capaces de funcionar en tiempo real. Estos sistemas detectan sobre el cuerpo humano un conjunto de puntos articulares o *keypoints* y los conectan formando una especie de esqueleto articulado, lo que permite estimar la pose de la persona en cada instante.

Biomedical Image Segmentation




Gómez et al., "Deep architectures for high-resolution multi-organ chest X-ray image segmentation", Neural Computing & Applications 32, 15949-15963, Springer, October – 2019

Gómez et al. "Deep architectures for the segmentation of frontal sinuses in X-Ray images: towards an automatic forensic identification system in comparative radiography", Neurocomputing 456, 575-585, Elsevier, October - 2021

56 of 92

Por supuesto, la visión por computador se utiliza de forma extensiva en el ámbito biomédico. En esta diapositiva vemos dos ejemplos de segmentación de imágenes médicas. A la izquierda, se muestra la segmentación de los senos frontales en radiografías de cráneo; y, a la derecha, la segmentación de distintas estructuras anatómicas (pulmones, clavículas y corazón) en radiografías de tórax.

Biomedical Image Classification




57 of 92

Otra aplicación biomédica sería la clasificación automática de lesiones gastrointestinales a partir de vídeos de colonoscopia convencional. En este caso se combinan distintas técnicas. Por un lado, se aplica Structure from Motion para reconstruir la forma 3D de la lesión a partir de vídeos adquiridos tanto con luz blanca como con NBI. A partir de esa reconstrucción 3D se extraen características relacionadas con la geometría de la lesión, mientras que de los frames 2D se obtienen características de color y textura. Toda esta información se integra posteriormente en un algoritmo de aprendizaje automático que, en términos prácticos, permite realizar la biopsia virtual y la reconstrucción tridimensional de la lesión.

Biomedical Image Analysis

Computational Pathology




Kumar, Neeraj, et al. "A dataset and a technique for generalized nuclear segmentation for computational pathology." *IEEE transactions on medical imaging* 36.7 (2017): 1550-1560.



Grimson, W. Eric L., et al. "Image-guided surgery." *Scientific American* 280.6 (1999): 62-69.

Image-guided Surgery




Maier-Hein, Lena, et al. "Optical techniques for 3D surface reconstruction in computer-assisted laparoscopic surgery." *Medical image analysis* 17.8 (2013): 974-996.

58 of 92

También podríamos mencionar la patología computacional. Por ejemplo, a partir de una imagen histológica es posible segmentar automáticamente células, tejidos u otras estructuras de interés y utilizar esa información como apoyo al diagnóstico médico. La visión por computador también se aplica en cirugía guiada por imagen, por ejemplo mediante técnicas de realidad aumentada que permiten superponer información relevante sobre la imagen adquirida en la sala de operaciones.

Audio-visual fusion for human-robot interaction



Lathuilière et al., "Neural Network-based Reinforcement Learning for Audio-Visual Gaze Control in Human-Robot Interaction", Pattern Recognition Letters, 2019

Lathuilière et al., "Deep reinforcement learning for audio-visual gaze control", IROS, 2018

59 of 92

También se puede utilizar la visión por computador en interacción humano-robot, por ejemplo en tareas de fusión audiovisual. En esta diapositiva vemos un robot humanoide equipado con cámaras que le permiten observar el entorno y cuyo objetivo es mantener una interacción lo más natural posible en un contexto conversacional. Para ello, se pueden emplear algoritmos de estimación de la pose corporal y de detección de personas (y caras), de manera que el robot pueda orientar la mirada hacia la persona que le está hablando y, cuando interactúa con un grupo, identificar quién se dirige a él y establecer contacto visual de forma adecuada.

En esta aplicación concreta se combinan distintas estrategias. Por un lado, se emplea aprendizaje por refuerzo para que el robot aprenda una política de comportamiento. Por otro, se utilizan redes neuronales recurrentes, en este caso LSTM, para procesar la secuencia temporal de observaciones y generar la siguiente acción que debe ejecutar el robot.

Forensic Human Identification through Craniofacial Superimposition



<https://panacea-coop.com>




<https://skeleton-id.com/>

60 of 92

La visión por computador también se puede aplicar en identificación humana forense y, por ejemplo, en la técnica denominada superposición craneofacial. Dado un modelo 3D postmortem de un cráneo, se busca proyectarlo en 2D sobre una fotografía antemortem de una persona candidata, con el objetivo de analizar el grado de solapamiento entre el cráneo y la cara y determinar si ambos son compatibles morfológicamente, es decir, si pueden corresponder a la misma persona.

Age Estimation from Dental Panoramic Radiographs



The most probable age for the individual is

18.24 years

with a minimum age of 15.59 years old according to the 95% prediction interval.

According to the results in our test sample, the individual has a 57% probability of being an adult.

The minimum age of the individual, using prediction intervals for coverage levels of 60, 80, 90, 95 and 99 percent, is 17.14, 16.52, 16.01, 15.59, and 14.57 years old. As a consequence, the maximum coverage for which the predicted age is larger than 18 years old is 0% (this is the coverage employed when the predicted age is below 19.1 years old). In this scenario, the probability of our system correctly classifying the individual as an adult is 88.88%.


Venema, J., De Luca, S., Mesejo, P., & Ibáñez, Ó. (2025). Trustworthy AI-based legal age estimation using orthopantomographs. *Applied Soft Computing*, 114386.

61 of 92

Dentro del mismo contexto forense, otra posible aplicación sería la estimación de la edad a partir de ortopantomografías, es decir, radiografías dentales panorámicas. En este caso concreto, dada una determinada radiografía dental, se podría emplear una red neuronal para proporcionar una estimación de la edad más probable. Además, podrían incorporarse estrategias como conformal prediction para ofrecer un intervalo de predicción asociado a dicha estimación.

También es posible incluir técnicas de explicabilidad que permitan identificar qué regiones de la imagen han influido más en la decisión del modelo. En esta diapositiva, por ejemplo, se resaltan en verde claro aquellas zonas de la dentadura que han tenido una mayor influencia en la red a la hora de realizar la predicción de la edad.

Optical Character Recognition (OCR)



Digit recognition, AT&T labs (1980s)
<http://yann.lecun.com/exdb/lenet/>




License plate readers

http://en.wikipedia.org/wiki/Automatic_number_plate_recognition

El reconocimiento óptico de caracteres, u Optical Character Recognition (OCR), constituye también una problemática clásica dentro de la visión por computador. Este tipo de técnicas permite reconocer automáticamente caracteres presentes en imágenes, ya se trate de texto manuscrito, texto impreso o, por ejemplo, los caracteres de una matrícula de vehículo.

Reconstruction of Ripped-Up Documents



Zhu, L., Zhou, Z., & Hu, D. (2007). Globally consistent reconstruction of ripped-up documents. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 30(1), 1-13.

63 of 92

La visión por computador también puede integrarse dentro de pipelines más amplios para resolver tareas complejas, como la reconstrucción digital de documentos que han sido rotos o triturados. En estos casos, el objetivo es identificar y emparejar automáticamente los distintos fragmentos para reconstruir, en la medida de lo posible, el documento original.

Earth viewers (3D modeling)



Image from Microsoft's [Virtual Earth](#)
(see also: [Google Earth](#))

64 of 92

También podríamos hablar de modelado 3D, como ocurre en visores del estilo de Google Earth. En este tipo de aplicaciones se busca reconstruir o representar tridimensionalmente el entorno, de manera que mapas, edificios y otros objetos puedan visualizarse con una apariencia 3D y percibirse con mayor sensación de profundidad y estructura espacial.

Special effects: shape and motion capture



Source: S. Seitz

65 of 92

En la industria cinematográfica también se emplean técnicas de visión por computador, por ejemplo para la generación e integración de efectos especiales.

Sports



Sportvision first down line

<https://entertainment.howstuffworks.com/first-down-line.htm>




Skillcorner Broadcast Tracking Technology

<https://medium.com/skillcorner/a-new-world-of-performance-insight-from-video-tracking-technology-f0d7c0deb767>

66 of 92



En el ámbito deportivo, la visión por computador también está ampliamente integrada, tanto en fútbol americano como en fútbol o baloncesto. Por ejemplo, puede utilizarse para superponer automáticamente la línea de primer down, detectar e identificar a los jugadores o realizar su seguimiento a lo largo del partido. Asimismo, permite extraer métricas cuantitativas sobre el comportamiento de los jugadores y el rendimiento colectivo de un equipo.

Robotics



<https://www.youtube.com/watch?v=tF4DML7FIWk>

<https://bostondynamics.com/blog/flipping-the-script-with-atlas/>



67 of 92

En robótica, la visión por computador lleva integrada desde hace décadas. Cuando un robot realiza una tarea, parece razonable pensar que, en muchas ocasiones, necesita percibir y explorar su entorno para poder desplazarse de forma segura. En este caso concreto estamos viendo el robot Atlas de Boston Dynamics, en su versión de 2021, que al desplazarse necesitaba detectar obstáculos, estimar la geometría del entorno y utilizar esa información para planificar y ejecutar sus movimientos.

Astronomy




Image created using ChatGPT

Galaxy Classification

Dieleman, S., Willett, K. W., & Dambre, J. (2015). Rotation-invariant convolutional neural networks for galaxy morphology prediction. *Monthly notices of the royal astronomical society*, 450(2), 1441-1459. <https://arxiv.org/pdf/1503.07077>

68 of 92

La visión por computador también desempeña un papel importante en astronomía. Por ejemplo, puede utilizarse para analizar automáticamente imágenes astronómicas y clasificar galaxias en función de su morfología, distinguiendo entre distintos tipos y estructuras a partir de las imágenes captadas por telescopios.


Astronomy

The New York Times

Darkness Visible, Finally: Astronomers Capture First Ever Image of a Black Hole

Astronomers at last have captured a picture of one of the most secretive entities in the cosmos.

April 10, 2019




Black Holes | The Edge of All We Know (2020)
<https://www.imdb.com/title/tt11863046/>

Bouman, Katherine L., et al.
"Computational imaging for VLBI image
reconstruction." *Proceedings of the
IEEE Conference on Computer Vision
and Pattern Recognition*. 2016.

69 of 92

Técnicas de visión por computador y procesamiento de imagen también desempeñaron un papel fundamental a la hora de obtener la primera imagen de un agujero negro. Evidentemente, no se fotografió luz procedente del interior del propio agujero negro, de donde no puede escapar, sino la radiación emitida por el plasma caliente que lo rodea a partir de las observaciones realizadas por distintos radiotelescopios.

Weather Prediction




"A single machine learning model can replace the entire NWP [numerical weather prediction] pipeline. [...] We believe that Aardvark Weather will be the starting point for a new generation of end-to-end models that will reduce computational costs by orders of magnitude and enable the rapid, affordable creation of customized models for a range of end users."

Allen, Anna, et al. "End-to-end data-driven weather prediction." *Nature* 641.8065 (2025): 1172-1179.

70 of 92

También se pueden emplear redes convolucionales y Vision Transformers en tareas de predicción meteorológica, utilizando como entrada observaciones procedentes de distintas fuentes, como sensores de satélite, radiosondas o estaciones meteorológicas. Estos modelos pueden aprender patrones espaciales y temporales de la atmósfera y utilizar esa información para predecir su evolución futura.

Neuroscience



Berg, S., Beckett, I. R., Costa, M., Schlegel, P., Januszewski, M., Marin, E. C., ... & Jefferis, G. S. (2026). Sexual dimorphism in the complete *Drosophila* male central nervous system connectome. *Cell*, 189(18), 5504-5526.

71 of 92

La visión por computador también se utiliza extensivamente en neurociencia. En esta diapositiva, por ejemplo, se parte de un enorme volumen de imágenes de microscopía electrónica del sistema nervioso central de *Drosophila*, la mosca de la fruta. A partir de esas imágenes es necesario localizar, segmentar y reconstruir cada neurona, así como identificar sus conexiones con otras neuronas. El objetivo final es reconstruir el conectoma completo de la mosca, es decir, el mapa de todas las neuronas y de las conexiones que existen entre ellas.


A bit of history

1960s-1970s

- It was **initially considered an easy step**

- In 1966, Marvin Minsky at MIT asked his undergraduate student Gerald Jay Sussman to *“spend the summer linking a camera to a computer and getting the computer to describe what it saw”* (Boden 2006, p. 781)

- Recover the **three-dimensional structure** of the world from images and to use this as a stepping stone **towards full scene understanding.**



Szeliski, R. (2022). Computer vision: algorithms and applications. Pages 9-18


73 of 92

A nivel histórico, los orígenes de la visión por computador pueden situarse en las décadas de 1960 y 1970. De hecho, como se recoge en la segunda edición del libro de Richard Szeliski (página 9), ya en 1966 Marvin Minsky, uno de los fundadores del Laboratorio de Inteligencia Artificial del MIT, propuso a un estudiante de grado dedicar el verano a conectar una cámara a un ordenador y conseguir que el ordenador describiese lo que veía. Evidentemente, formulado de esta manera el problema parece mucho más sencillo de lo que realmente es. De hecho, sesenta años después seguimos trabajando para conseguir que las máquinas sean capaces de interpretar y describir su entorno visual de manera verdaderamente eficaz, robusta y generalizable.

Algunas de las problemáticas que se abordaron durante los años 70 incluyen la extracción de bordes, el modelado 3D de objetos, el análisis de las variaciones de intensidad y sombreado, así como la correspondencia estéreo de características. Es importante entender que, en visión por computador, cuando hablamos de visión estéreo nos referimos a utilizar dos puntos de vista diferentes, de manera análoga a nuestros dos ojos. Como los ojos están separados, no perciben exactamente la misma imagen del entorno, y esa pequeña discrepancia entre ambas vistas constituye una de las principales pistas que utiliza nuestro sistema visual para estimar la profundidad. Durante estos años también comenzaron a estudiarse técnicas de optical flow, o flujo óptico, cuyo objetivo es estimar el movimiento aparente de los elementos de una escena a partir de una secuencia de imágenes.

1980s

- More sophisticated mathematical techniques for performing **quantitative image and scene analysis**.



Szeliski, R. (2022). Computer vision: algorithms and applications. Pages 9-18

74 of 92

Si nos vamos ya a los años 80, empiezan a aparecer técnicas más sofisticadas para el análisis de escenas. Se trabaja, por ejemplo, en fusión de imágenes o image blending, y en técnicas de shape from shading, cuyo objetivo es inferir la forma tridimensional de una superficie a partir de las variaciones de iluminación y sombreado presentes en una imagen. Se continúa profundizando también en la detección de bordes, aparecen los modelos deformables, que posteriormente tendrán un papel muy importante en segmentación, y se avanza en la reconstrucción de superficies tridimensionales. En este contexto también se empieza a trabajar con lo que se denomina range data acquisition and merging. Los range data son, esencialmente, medidas de distancia o profundidad: para distintos puntos de una escena se estima a qué distancia se encuentran del sensor, obteniendo una representación tridimensional parcial de la superficie. Como normalmente una única observación no permite ver todo el objeto, se adquieren datos desde distintos puntos de vista y posteriormente se registran y fusionan esas distintas mediciones para construir un único modelo 3D más completo de la escena o del objeto.

1990s

- Much of the previously mentioned topics continued to be explored.
- A lot of the activity was directed at **projective reconstructions**.
- **Multi-view algorithms** that produce **complete 3D surfaces** were also an active topic of research.
- Increased **interaction with computer graphics**.

Structure-from-motion
using orthographic
camera approximations



(a)

Dense stereo
matching




(b)

Multi-view
reconstruction




(c)



(d)

Face tracking



(e)

Image
segmentation



(f)

Face recognition

Szeliski, R. (2022). Computer vision: algorithms and applications. Pages 9-18

75 of 92

En los años 90 se continúa profundizando en muchos de los problemas anteriores, pero una parte importante de la investigación se orienta hacia la reconstrucción proyectiva y hacia técnicas de Structure from Motion, que permiten recuperar información sobre la estructura tridimensional de una escena y el movimiento de la cámara a partir de una secuencia de imágenes. También se desarrollan algoritmos multivista capaces de combinar varias imágenes para obtener reconstrucciones 3D cada vez más completas. Al mismo tiempo, aumenta notablemente la interacción entre computer graphics y visión por computador.

Durante esta década se trabaja asimismo en problemas como image segmentation, face tracking (es decir, seguimiento de caras a lo largo de una secuencia) y face recognition, cuyo objetivo es reconocer la identidad de una persona a partir de su rostro. También se desarrollan técnicas de dense stereo matching, que buscan establecer correspondencias de forma densa entre dos imágenes obtenidas desde puntos de vista ligeramente diferentes, idealmente encontrando para cada píxel de una imagen el píxel correspondiente en la otra. A partir de estas correspondencias se puede calcular la disparidad y, con ella, recuperar información sobre la profundidad de la escena.

2000s


- This decade continued to deepen the **interplay between the vision and graphics fields**, but more importantly embraced **data-driven and learning approaches** as core components of vision.

Image-based rendering (new views of the scene)



(a)

Image-based modeling (generate a 3D model)



(b)

Interactive tone mapping (computational photography)



(c)



(d)

Texture synthesis



(e)

Feature-based techniques for object recognition



(f)

Region segmentation

Szeliski, R. (2022). Computer vision: algorithms and applications. Pages 9-18

76 of 92


Cuando llegamos al siglo XXI, se continúa investigando en muchas de las temáticas anteriores y se profundiza en la interacción, cada vez mayor, entre visión por computador y computer graphics. Sin embargo, uno de los elementos que caracteriza especialmente estos años es la creciente importancia de las aproximaciones basadas en datos y aprendizaje. Es decir, comienzan a popularizarse en visión por computador las técnicas de aprendizaje automático, en las que los modelos aprenden determinados patrones directamente a partir de conjuntos de datos.

Junto con ello, se continúa trabajando en segmentación de imágenes y se desarrollan áreas como la síntesis de texturas, la fotografía computacional y el modelado y renderizado basados en imágenes. El modelado busca construir una representación, frecuentemente tridimensional, de un objeto o una escena a partir de imágenes, mientras que el renderizado consiste en generar imágenes de esa representación, por ejemplo para visualizar la escena desde nuevos puntos de vista. La fotografía computacional experimentó un gran impulso a partir de los años 2000, en buena medida gracias a la incorporación de cámaras en los teléfonos móviles.

2010s

- Trend towards using **large labeled (and also self-supervised) datasets** to develop **machine learning** algorithms.
- **Specialized sensors and hardware** for computer vision tasks also continued to advance.
- Incredible advances in the **performance and reliability** of computer vision algorithms.

Deep convolutional neural networks for visual recognition




(a)

Object instance segmentation




(b)

Person's 3D model with gestures and expression from a single image



(c)




(d)

Fusing multiple color depth images in real-time



(e)

Smartphone augmented reality



(f)


3D map computed in real-time on a fully autonomous drone

Szeliski, R. (2022). Computer vision: algorithms and applications. Pages 9-18

77 of 92


Finalmente, durante la segunda década del siglo XXI se generaliza el uso de grandes conjuntos de datos etiquetados y se produce, en buena medida, la transición desde técnicas clásicas de machine learning hacia deep learning. Las redes neuronales profundas comienzan a dominar muchas tareas de reconocimiento visual y permiten abordar problemas cada vez más complejos.

Durante estos años se profundiza, por ejemplo, en segmentación de instancias y reconocimiento visual mediante redes profundas. Al mismo tiempo, aparecen sensores y hardware cada vez más especializados, lo que permite desplegar sistemas de visión en escenarios más exigentes: drones capaces de percibir y reconstruir en tiempo real la estructura 3D de su entorno, numerosas aplicaciones de visión en dispositivos móviles o sistemas capaces de fusionar en tiempo real información procedente de distintas cámaras o sensores.



En esta diapositiva se puede ver el esquema visual de la evolución histórica de la visión por computador que presenta Richard Szeliski en su libro. La línea temporal parte de comienzos de los años 70, con el procesamiento digital de imágenes, y llega hasta la década de 2020, marcada por deep learning y por una integración cada vez mayor entre visión y lenguaje. A día de hoy, uno de los ejemplos más paradigmáticos de esta convergencia son los Vision-Language Models, o VLMs, capaces de procesar conjuntamente información visual y textual.

“Classic” recognition pipeline



Hand-crafted feature representation

+

Off-the-shelf trainable classifier

79 of 92

Si nos centramos en el uso de aprendizaje automático en tareas de visión por computador, el pipeline clásico partiría directamente de los píxeles de la imagen. A partir de ellos se extraería una representación de la imagen, es decir, un conjunto de características diseñadas previamente por expertos humanos. Posteriormente, estas características se utilizarían para entrenar un modelo de aprendizaje automático; por ejemplo, si estamos ante un problema de clasificación, un clasificador que produciría como salida la clase predicha.

Por tanto, en esta aproximación clásica podemos distinguir claramente dos etapas secuenciales: por un lado, la extracción de características diseñadas manualmente y, por otro, el entrenamiento de un clasificador utilizando esas características como entrada.

Deep Learning



Yoshua Bengio
University of Montreal



Geoffrey Hinton
University of Toronto & Google



Yann LeCun
New York University & Facebook

Turing Award 2018

<https://awards.acm.org/about/2018-turing>

80 of 92

Pero con la llegada del deep learning todo esto cambia de manera sustancial. Antes de hacer una brevísima introducción a lo que entendemos por deep learning, esta diapositiva nos sirve para dimensionar el enorme impacto que ha tenido esta tecnología. En 2018, el Turing Award, considerado habitualmente como una especie de equivalente al Premio Nobel en ciencias de la computación, fue concedido a Yoshua Bengio, Geoffrey Hinton y Yann LeCun precisamente por sus contribuciones fundamentales al desarrollo del deep learning. Es decir, hace ya ocho años se reconocía al máximo nivel la importancia que estas técnicas habían adquirido dentro de la informática.

Deep Learning

Fundación Princesa de Asturias

#PremiosPrincesadeAsturias

PREMIOS PRINCESA DE ASTURIAS | PREMIADOS

GALARDONADOS CON LOS PREMIOS PRINCESA DE ASTURIAS 2022

LISTA COMPLETA DE PREMIADOS >

Todas las categorías

2022 Nombre

BUSCAR

 ARTES CARMEN LINARES Y MARÍA PAGÉS	 CIENCIAS SOCIALES EDUARDO MATOS MOCTEZUMA	 COMUNICACIÓN Y HUMANIDADES ADAM MICHNIK	 CONCORDIA SHIGERU BAN
 COOPERACIÓN INTERNACIONAL ELLEN MACARTHUR	 DEPORTES FUNDACIÓN Y EQUIPO OLÍMPICO DE REFUGIADOS	 INVESTIGACIÓN CIENTÍFICA Y TÉCNICA GEOFFREY HINTON, YANN LECUN, YOSHUA BENGIO Y DEMIS HASSABIS	 LETRAS JUAN MAYORGA


<https://www.fpa.es/es/especial-2022/premiados/>

81 of 92

Y este reconocimiento se extendió también a los Premios Princesa de Asturias de 2022. En la categoría de Investigación Científica y Técnica fueron galardonados nuevamente Geoffrey Hinton, Yann LeCun y Yoshua Bengio, en esta ocasión junto con Demis Hassabis, cofundador y entonces CEO de DeepMind, por sus contribuciones al desarrollo de la inteligencia artificial y, en particular, de las técnicas de aprendizaje profundo.

Deep Learning

The Nobel Prize in Physics 2024



The Nobel Prize in Physics 2024 was awarded jointly to John J. Hopfield and Geoffrey E. Hinton "for foundational discoveries and inventions that enable machine learning with artificial neural networks"

The Nobel Prize in Chemistry 2024




The Nobel Prize in Chemistry 2024 was divided, one half awarded to David Baker "for computational protein design", the other half jointly to Demis Hassabis and John M. Jumper "for protein structure prediction"

<https://www.nobelprize.org/all-nobel-prizes-2024/>

82 of 92

Finalmente, en 2024, cuatro investigadores estrechamente relacionados con la inteligencia artificial fueron galardonados con el Premio Nobel. John Hopfield y Geoffrey Hinton recibieron el Premio Nobel de Física por sus contribuciones fundamentales al aprendizaje automático mediante redes neuronales artificiales. Por su parte, Demis Hassabis y John Jumper recibieron, junto con David Baker, el Premio Nobel de Química por sus trabajos relacionados con la predicción de la estructura tridimensional de las proteínas. Todo ello permite dimensionar el enorme impacto que ha tenido el deep learning, no solamente en visión por computador, sino también en muchos otros ámbitos, y hasta qué punto estas técnicas han transformado la ciencia y la tecnología durante los últimos diez o quince años.

Hierarchical Learning



Deep learning allows computational models that are composed of **multiple processing layers to learn representations of data with multiple levels of abstraction.**

Yann LeCun, Yoshua Bengio, and Geoffrey Hinton. "Deep learning." *Nature* 521.7553 (2015): 436-444.

83 of 92

Si ahora nos centramos brevemente en qué es el deep learning y en qué cambio supuso con respecto al pipeline clásico, podríamos decir que una de sus características fundamentales es que permite aprender representaciones jerárquicas directamente a partir de los propios datos de entrada. Es decir, ya no se separan de manera rígida y explícita la extracción de características y la posterior clasificación o regresión, sino que ambas etapas quedan integradas dentro de un mismo modelo que puede entrenarse de extremo a extremo.

Si acudimos al ya clásico artículo de LeCun, Bengio y Hinton publicado en *Nature* en 2015, allí se describe como el uso de modelos computacionales compuestos por múltiples capas de procesamiento capaces de aprender representaciones de los datos con múltiples niveles de abstracción. La idea es precisamente que las primeras capas aprendan representaciones relativamente simples y que, a medida que avanzamos por la red, estas se combinan para formar representaciones progresivamente más abstractas y complejas.

En este sentido, en esta diapositiva vemos un ejemplo de reconocimiento facial. Dada una imagen de entrada, el objetivo es clasificarla asignándole la identidad correspondiente, por lo que estaríamos ante un problema de clasificación multiclase. En el ejemplo aparece una imagen de Albert Einstein, seguida de una representación simplificada de una red neuronal como una sucesión de nodos conectados entre sí, y a la derecha la salida esperada sería precisamente la etiqueta "Albert Einstein".

En determinadas arquitecturas aplicadas en visión, especialmente en redes convolucionales, se ha podido observar y visualizar cómo las representaciones aprendidas tienden a aumentar su nivel de abstracción a medida que avanzamos hacia capas más profundas de la red. En las capas más próximas a la imagen se aprenden características de bajo nivel, como bordes, esquinas o formas sencillas. En capas intermedias, estas características se combinan para representar patrones más complejos, como ojos, narices o bocas. Finalmente, en las capas más profundas pueden aparecer representaciones de alto nivel asociadas con configuraciones faciales mucho más específicas, relacionadas con la fisonomía o la identidad. Por tanto, de izquierda a derecha, la red va construyendo representaciones cada vez más abstractas y semánticamente más ricas.

Some of the Main Current Limitations

Y así llegamos a algunas de las principales limitaciones actuales de los sistemas de visión por computador y, más ampliamente, de los sistemas de inteligencia artificial en general. Evidentemente, lo que se presenta a continuación no deja de ser una selección limitada, incompleta y en cierta medida personal de estas limitaciones, que requerirían una discusión mucho más amplia y profunda, con muchos más detalles, ejemplos y matices.

Some of the Main Current Limitations

- Machines can outperform humans at **concrete, well-defined tasks**, but they struggle at more general and abstract tasks.




85 of 92

A pesar de que nuestras máquinas son cada vez más eficaces en un abanico más amplio de tareas (y los sistemas agénticos y multimodales constituyen un ejemplo paradigmático de esta evolución), creo que todavía puede afirmarse que los sistemas actuales tienden a rendir especialmente bien en tareas concretas y bien definidas, mientras que presentan mayores dificultades cuando deben enfrentarse a problemas más generales, abiertos o abstractos.

De hecho, muchos sistemas actuales pueden alcanzar un rendimiento muy notable en tareas cuya solución es relativamente fácil de verificar, como ocurre, por ejemplo, en programación. Sin embargo, cuando hablamos de tareas que exigen una toma de decisiones más abierta, la integración de información heterogénea, la concatenación de múltiples subtareas o el desarrollo autónomo de un trabajo completo durante periodos prolongados, las limitaciones siguen siendo mucho más evidentes.

Some of the Main Current Limitations (2)

- Many times, your system is hard to analyze (**black box**) and it's only going to be **as good as the data you have**.
 - Serious ethical, practical, legal problems...



Recommended reading:

"The Neural Net Tank Urban Legend" <https://gvern.net/tank>

86 of 92

Otra limitación clásica está asociada precisamente con una de las herramientas que ha protagonizado muchos de los grandes avances de la inteligencia artificial y de la visión por computador durante los últimos años: las redes neuronales. Estos modelos pueden alcanzar un rendimiento extraordinario, pero muchas veces resultan difíciles de interpretar y analizar. El sistema toma una determinada decisión, pero no siempre es sencillo comprender qué información ha utilizado realmente para llegar a ella. Además, como ocurre con cualquier técnica de aprendizaje automático, su comportamiento depende de los datos utilizados para entrenarla. Y todo ello puede tener importantes implicaciones prácticas, éticas y legales.

Existe una anécdota clásica en inteligencia artificial (probablemente apócrifa, pero muy ilustrativa) sobre un sistema entrenado para determinar si en una determinada imagen aparecía o no un tanque. Según la historia, los investigadores consiguieron un rendimiento excelente sobre sus propios datos, pero cuando el sistema fue evaluado con un conjunto de imágenes verdaderamente independiente su rendimiento cayó prácticamente al nivel del azar. Al investigar qué había sucedido, se descubrió que el modelo no había aprendido realmente a reconocer tanques, sino determinadas características visuales espurias que estaban correlacionadas con las etiquetas del conjunto de entrenamiento.

Aunque esta anécdota concreta sea falsa, la idea que ilustra, sin embargo, es completamente real. Un modelo supervisado no sabe por sí mismo qué correlaciones son causalmente relevantes para resolver el problema y cuáles son simplemente accidentales. Si, como ocurre en el ejemplo de esta diapositiva, todas las imágenes con tanques presentan tonalidades ocre, arena o desierto, mientras que las imágenes sin tanques contienen vegetación y tonalidades verdes, el modelo podría aprender perfectamente la regla espuria «marrón implica tanque y verde implica ausencia de tanque». En ese caso, al presentarle un tanque situado en medio de un bosque o de un prado, podría clasificarlo erróneamente como «no tanque». El modelo habría aprendido a resolver perfectamente el dataset, pero no necesariamente el problema que nosotros queríamos que resolviese.

Some of the Main Current Limitations (3)

- **Deep learning generally requires too much data (and energy)**
 - Humans don't usually need to see 5000 images of different cats to reliably identify one.



Image taken from <https://www.fourpaws.com/>

87 of 92


Por otro lado, muchos de los modelos más potentes actuales requieren cantidades enormes de datos y recursos computacionales para su entrenamiento. Desde el punto de vista de la eficiencia y de la economía de medios, esto los sitúa todavía bastante lejos de la inteligencia humana: como pauta general, una persona no necesita observar miles de ejemplos diferentes de gatos para aprender a reconocer uno. Del mismo modo que, para aprender a conducir un coche, no necesitamos millones de horas de conducción etiquetada.

Esta cuestión podría desarrollarse en muchas direcciones. Una de ellas es el consumo energético. Aunque entrenar grandes modelos puede requerir una cantidad muy considerable de energía, en sistemas desplegados a gran escala el coste acumulado de la inferencia también puede llegar a ser enorme e incluso superar al del entrenamiento a lo largo de la vida útil del modelo. Recordemos que, una vez desplegado, el sistema puede recibir cientos de millones de consultas. Cada inferencia individual puede tener un coste relativamente pequeño, pero cuando se multiplica por una utilización masiva y continua, el consumo total se vuelve muy significativo.

Precisamente por ello, varias líneas actuales de investigación buscan mejorar la eficiencia de estos sistemas: aprender con muchos menos ejemplos, reducir el coste computacional tanto del entrenamiento como de la inferencia y, en general, desarrollar modelos capaces de obtener prestaciones similares utilizando menos recursos y con un menor impacto energético.

Some of the Main Current Limitations (and 4)

- **Machines have limited semantic grounding**
 - They rely on learned statistical patterns
 - They can struggle to “see the whole”



Deep neural networks are easily fooled: High confidence predictions for unrecognizable images (CVPR 2015)

88 of 92


No olvidemos también que estos sistemas carecen de voluntad o de objetivos propios: operan a partir de las señales que reciben, de los objetivos que se les han definido y de los parámetros aprendidos durante el entrenamiento. Como pauta general, una vez entrenado un modelo, esos parámetros permanecen fijos durante la inferencia, de modo que el sistema aplica el conocimiento estadístico adquirido a las nuevas entradas (desde este punto de vista, se aplica siempre la misma solución aprendida). Esto puede hacer que tenga dificultades para interpretar una situación de manera global o para incorporar el tipo de contexto y conocimiento del mundo que utilizamos los seres humanos.

En esta diapositiva vemos un ejemplo clásico, publicado en 2015, que quizá pueda parecer antiguo, pero que sigue ilustrando bastante bien este problema. Se muestran una serie de imágenes sintéticas que para nosotros no representan ningún dígito reconocible y que, sin embargo, una red neuronal clasificaba con una confianza extremadamente elevada como determinados dígitos (mostrados en la fila superior, sobre cada columna). Así, las imágenes de la primera columna eran clasificadas como ceros, las de la segunda como unos, las de la tercera como doses, y así sucesivamente.

Lo que pone de manifiesto este ejemplo es que el modelo no necesita reconocer el concepto de dígito de la misma manera que lo haría una persona. Ha aprendido determinados patrones estadísticos que resultaban útiles para discriminar las clases durante el entrenamiento y, cuando esas imágenes sintéticas provocan activaciones compatibles con dichos patrones, puede producir una predicción con enorme confianza aunque, desde nuestra perspectiva, la imagen no se parezca en absoluto al dígito correspondiente. Es una buena ilustración de que una confianza predictiva elevada no implica necesariamente una comprensión semántica de aquello que se está observando.

Some of the Main Current Limitations (and 4)

- **Machines have limited semantic grounding**
 - They rely on learned statistical patterns
 - They can struggle to “see the whole”



Adversarial Example extracted from <https://www.labsix.org/physical-objects-that-fool-neural-nets/> (2017)

89 of 92

Aquí tendríamos otro ejemplo representativo. Para un ser humano, en ambas imágenes aparece claramente un gato: a la izquierda ligeramente rotado y a la derecha centrado. Sin embargo, en este ejemplo de 2017, el sistema de clasificación identificaba correctamente, y con gran confianza en la predicción, una de las imágenes (la de la izquierda) como un gato, mientras que, tras una pequeña transformación geométrica de la imagen, pasaba a clasificarla prácticamente con un 100 % de confianza como guacamole (imagen de la derecha).

De nuevo, este ejemplo ilustra cómo modificaciones relativamente pequeñas y semánticamente irrelevantes para un ser humano pueden provocar cambios drásticos en la predicción de una red neuronal. El modelo no está necesariamente reconociendo el objeto de una forma equivalente a nosotros, sino explotando los patrones estadísticos aprendidos durante el entrenamiento, lo que puede dar lugar a errores catastróficos ante perturbaciones aparentemente menores.

Some of the Main Current Limitations (and 4)

- **Machines have limited semantic grounding**
 - They rely on learned statistical patterns
 - They can struggle to “see the whole”



For more recent work on the current challenges regarding adversarial robustness in traffic sign recognition, see:

- [Zhou et al.](#), IEEE TIFS, 2024
- [Khan et al.](#), CVPRW, 2025
- [Fawole & Rawat](#), ACM CSUR, 2025
- [Andleeb et al.](#), IJCC, 2026

<https://spectrum.ieee.org/slight-street-sign-modifications-can-fool-machine-learning-algorithms>

90 of 92

Y en esta diapositiva podemos ver otro ejemplo, también de 2017, en el que pequeñas modificaciones realizadas sobre una señal de tráfico pueden hacer que un sistema de visión deje de reconocer correctamente una señal de STOP y pase a ignorarla o a clasificarla como otra señal diferente. Uno podría pensar que, tratándose de un ejemplo de 2017, este tipo de vulnerabilidades están ya superadas, pero no es así. En este sentido, pueden consultarse también las referencias complementarias incluidas a la derecha, publicadas en los últimos años, que muestran que, a pesar de todos los avances, la robustez frente a perturbaciones y ataques adversarios continúa siendo un problema abierto en el reconocimiento de señales de tráfico.

Some of the Main Current Limitations (and 4)

- **Machines lack a physical model of the world**



Prompt: Archeologists discover a generic plastic chair in the desert, excavating and dusting it with great care.

Weakness: In this example, Sora fails to model the chair as a rigid object, leading to **inaccurate physical interactions**.



Prompt: Five gray wolf pups frolicking and chasing each other around a remote gravel road, surrounded by grass. The pups run and leap, chasing each other, and nipping at each other, playing.

Weakness: Animals or people can **spontaneously appear**, especially in scenes containing many entities.

<https://openai.com/sora> (15 Feb 2024)

<https://openai.com/research/video-generation-models-as-world-simulators>

91 of 92

Una cuarta limitación que podemos señalar es que los modelos actuales no disponen de un modelo físico y consistente del mundo. En esta diapositiva pueden verse dos vídeos publicados en la propia página web de Sora, de OpenAI, en los que determinadas propiedades físicas y espaciales no se mantienen de forma coherente a lo largo del tiempo. Por ejemplo, a la derecha aparecen nuevos cachorros como por generación espontánea, mientras que, a la izquierda, una silla (aparentemente, de plástico rígido) cambia de estructura e incluso parece desafiar la gravedad.

¿Por qué pueden producirse este tipo de errores? No es fácil dar una respuesta única, entre otras cosas porque estamos hablando de modelos tremendamente sobre-parametrizados, entrenados sobre cantidades masivas de datos (no tenemos una idea clara de qué ejemplos han participado del entrenamiento de estos modelos) y cuyo funcionamiento interno resulta difícil de interpretar. Estos sistemas aprenden regularidades estadísticas presentes en los datos sin que el proceso de entrenamiento les obligue necesariamente a construir y respetar de forma explícita leyes físicas como la gravedad, la conservación de los objetos o determinadas relaciones causales. Recordemos que estamos ante máquinas correlacionales y no causales.

Take-home message

Despite the obvious successes achieved, current AI systems:

- Often require **large amounts of data** to learn about the world
- Can require **substantial computational resources and energy**
- Can **fail unexpectedly** or be **fooled by surprisingly simple perturbations**
- Perform best on **well-defined tasks**
- Their **behavior can be difficult to analyze** and understand

“We just don’t have machines with common sense”
(Yann LeCun, 2019)

Machines, no matter how sophisticated they are, do not solve problems, they execute solutions

92 of 92

Finalmente, a modo de conclusión, y a pesar de los evidentes éxitos alcanzados a lo largo de los 70-75 años de historia de la inteligencia artificial, los sistemas actuales siguen presentando limitaciones importantes, muchas de ellas directamente extrapolables a visión por computador.

En términos generales, todavía suelen necesitar grandes cantidades de datos para aprender determinadas propiedades del mundo, pueden consumir una cantidad muy notable de recursos computacionales y energéticos, pueden ser vulnerables a perturbaciones y ser engañados con relativa facilidad, suelen desenvolverse mejor en tareas concretas y bien definidas (sobre todo cuando los resultados son verificables) y su comportamiento interno puede resultar difícil de analizar e interpretar.

En un sentido más amplio, podemos recuperar una frase de Yann LeCun de 2019 que, a mi juicio, continúa siendo pertinente: todavía no disponemos de máquinas con sentido común.

Y conviene recordar además que, por muy sofisticados que sean estos sistemas, en último término, no resuelven problemas sino que ejecutan soluciones. Los seres humanos no tenemos por qué proporcionarles explícitamente la solución, pero sí definimos la arquitectura, los datos, los objetivos y el procedimiento mediante el cual pueden aprender una estrategia para resolver una determinada tarea. Durante el entrenamiento aprenden patrones y representaciones a partir de los datos y, posteriormente, durante la inferencia, aplican ese conocimiento aprendido a nuevas entradas.

De hecho, existen diversas publicaciones, que puedo proporcionar al alumnado en caso de que sea de su interés, en las que se ponen de manifiesto las limitaciones actuales incluso de los sistemas más avanzados a la hora de realizar open-ended research, es decir, investigación científica abierta en la que no existe un procedimiento claramente delimitado de antemano y es necesario decidir qué preguntas formular, qué hipótesis explorar y qué pasos seguir. Algo similar ocurre con determinadas formas de razonamiento. Los modelos actuales pueden desenvolverse razonablemente bien en tareas de razonamiento deductivo e inductivo, pero presentan mayores dificultades cuando hablamos de razonamiento abductivo, es decir, cuando a partir de unas observaciones es necesario proponer la explicación o hipótesis más plausible que pueda dar cuenta de ellas. Artículos recientes muestran que incluso modelos del estado del arte pueden fallar de forma sorprendente en tareas que requieren sentido común, llegando a violar principios físicos cotidianos o a equivocarse ante situaciones que para un ser humano resultarían sencillas de interpretar.

Introduction

Pablo Mesejo

pmesejo@go.ugr.es

Universidad de Granada

Departamento de Ciencias de la Computación e Inteligencia Artificial



UNIVERSIDAD
DE GRANADA



DaSCI

Instituto Andaluz de Investigación en
Data Science and Computational Intelligence